

Abstract—L'équité est une préoccupation majeure dans l'apprentissage profond, car ces modèles sont de plus en plus utilisés pour prendre des décisions ayant un impact direct sur les individus. Or, des biais présents dans les données ou les algorithmes peuvent conduire à des résultats discriminatoires, en particulier pour les groupes sous-représentés. Il est donc essentiel de veiller à ce que ces systèmes fonctionnent de manière juste et équilibrée pour l'ensemble des populations concernées. Au travers du modèle CLIP [6] de OpenAI, nous avons exploré au cours de ce projet différentes techniques de mitigation des biais appliquées au jeu de données Harvard-FairVLMed [1] d'imagerie médicale.

1. Introduction

Étant grandement intéressé par la recherche dans le domaine de l'IA, je me suis naturellement tourné vers un projet avec l'objectif d'en faire une sorte d'ouverture vers ce monde-là. Madame Heliou voulant bien nous encadrer, nous venions d'obtenir un cap relativement clair pour la suite : trouver des problématiques récentes liées à la fairness. Après une phase de recherches documentaires, nous avons sélectionné trois sujets d'étude : l'impact du prompt engineering sur l'équité d'un modèle, l'effet de la quantization et des techniques de compression de modèles sur leur fairness, et enfin une étude approfondie de CLIP, sujet que nous avons retenu et dont la présentation ci-dessous du modèle, je l'espère, éclaircira les motivations derrière ce choix.

2. Présentation du modèle

CLIP[6] (pour Contrastive Language–Image Pre-training) est un modèle multimodal développé par OpenAI, capable de comprendre conjointement des images et du langage naturel. L'idée centrale est d'entraîner un réseau de neurones à associer des images à leurs descriptions textuelles à l'aide d'un apprentissage contrastif. Contrairement aux modèles traditionnels entraînés pour une tâche spécifique, CLIP est préentraîné sur un vaste corpus de paires image–texte issues d'internet, ce qui lui permet d'apprendre des concepts visuels de manière générale à partir du langage.

Le modèle CLIP est composé de deux encodeurs distincts : un encodeur d'image (généralement un ResNet ou un Vision Transformer) et un encodeur de texte (basé sur un transformeur). Pendant l'entraînement, chaque image et chaque texte sont projetés dans un espace d'embedding commun. CLIP apprend alors à rapprocher les représentations des paires image–texte correspondantes, tout en éloignant celles des paires non correspondantes.

Grâce à cette architecture, CLIP est naturellement adapté à l'apprentissage zero-shot. Dans ce cadre, il peut effectuer des tâches de classification ou de reconnaissance sans entraînement supplémentaire, simplement en comparant l'image à différentes descriptions textuelles possibles (par exemple : « une photo d'un chat », « une image d'un cerveau »). Il suffit alors d'utiliser le texte comme interface flexible pour spécifier de nouvelles classes ou tâches, même si le modèle ne les a jamais vues explicitement pendant l'entraînement.

Cette capacité à généraliser à de nouvelles tâches sans réentraînement fait de CLIP un outil puissant et polyvalent dans le domaine de l'intelligence artificielle multimodale, applicable à des tâches variées comme la classification, la recherche d'images ou la compréhension de scènes complexes.

Fig. 1 montre comment est réalisé l'entraînement: on calcule pour chaque paire (text,image) leur similarité-cosinus: $\cos \theta = \frac{A \cdot B}{\|A\| \|B\|}$, $A, B \in \mathbb{R}^n$, plus il est proche de -1 plus la sémantique du texte "s'éloigne" de celle de l'image d'après le modèle. Ainsi, l'entraînement

cherchera à maximiser la diagonale principale de la matrice ci-dessous.

1. Contrastive pre-training




Figure 1. Méthodologie d'entraînement contrastif de CLIP [5].

Il en résulte un espace latent très structuré assez intuitif d'utilisation et donc un très bon cadre pour l'étude de la fairness.

3. Zoom sur la Fairness

L'équité en apprentissage automatique fait référence à la capacité d'un modèle à traiter équitablement l'ensemble des individus ou des groupes, indépendamment de caractéristiques sensibles telles que le genre, l'origine ethnique, l'âge ou le statut socio-économique, que l'on appellera le plus souvent "attribut sensible" et dont la suppression est loin d'être la réponse optimale au problème. Dans ce contexte, plusieurs définitions formelles de l'équité ont été proposées, parmi lesquelles on trouve la parité démographique, l'égalité des chances ou encore la neutralité prédictive.

Dans le cadre de ce projet, nous avons utilisé la bibliothèque AI Fairness 360 (AIF360), développée par IBM Research [2], qui fournit un ensemble d'outils open source pour détecter, mesurer et atténuer les biais dans les modèles d'apprentissage automatique.

Métrique	Formule ou description
Base Rate	$P(Y = 1 D = d)$
Statistical Parity Difference (SPD)	$P(\hat{Y} = 1 D = np) - P(\hat{Y} = 1 D = p)$
Disparate Impact (DI)	$\frac{P(\hat{Y} = 1 D = np)}{P(\hat{Y} = 1 D = p)}$
Equal Opportunity Difference (EOD)	$P(\hat{Y} = 1 Y = 1, D = np) - P(\hat{Y} = 1 Y = 1, D = p)$
Average Odds Difference (AOD)	Moyenne des différences de TPR et FPR entre les groupes
Conditional Demographic Disparity (CDD)	Évalue la disparité selon les features conditionnelles
Bias Amplification (BA)	Mesure l'amplification d'un biais existant par le modèle

Table 1. Métriques d'équité clés utilisées dans ce projet.

Légende : Y : vraie étiquette, $\hat{Y}$: prédiction, D : attribut protégé, p : groupe privilégié, np : groupe non privilégié $TPR : \frac{TP}{TP+FN}$ $FPR : \frac{FP}{FP+TN}$

4. Premiers pas avec le modèle

4.1. FairFace

FairFace est un dataset de photos de visages très utilisé pour tester l'équité des modèles, que nous avons découvert durant la phase initiale de recherche. Il semblait être un bon candidat pour réaliser une batterie de tests initiaux sur CLIP, afin d'observer quels types de biais sociétaux et autres stéréotypes il avait pu intégrer, compte tenu de la provenance peu contrôlée des paires image-texte utilisées lors de son entraînement. Dans la suite, nous nous concentrerons sur la prédiction de l'ethnie pour illustrer ces biais.




Figure 2. Composition de quelques dataset de visages connus[3].

On notera tout d'abord que CLIP a une précision d'environ 28%, ce qui indique que les prédictions ne sont pas aléatoires. On s'est intéressé à la sensibilité de CLIP par rapport à de légers changements de formulations, soit en renommant le mot-clé représentant la classe, ou bien le contexte autour de celui-ci :

Catégorie original	Potentiel changement
White	Caucasian
Black	African Descent
East Asian	/
Indian	South Asian
Southeast Asian	/
Latino_Hispanic	Latino/Hispanic
Middle Eastern	/

Phrases testées avec CLIP

"portrait of a ... individual"
 "person with ... features"
 "photo of someone of ... heritage"
 "a face photo of a ... person"

Nous avons ainsi observé des variations notables sur certains changements de formulation. Il semblerait qu'ajouter du contexte au descripteur de la classe, i.e. donner en entrée "une image d'un individu blanc", soit systématiquement meilleur que juste donner "blanc". On notera également que les expressions telles que "caucasian" ou "african descent" améliorent la fairness car elles sont plus reliées sémantiquement à l'homme que de simples couleurs. Pour le changement "White" -> "Caucasian", on note une amélioration du taux d'erreur de 55%. Néanmoins, les changements de prédictions liés aux changements de phrases du second tableau sont nettement plus durs à prédire et à interpréter, notons que la formulation "photo of someone of heritage" semble être la plus performante. On s'est ensuite penché sur ce qui se trouve "autour" de nos catégories originales. En l'absence d'un décodeur (indisponible en open source du moins), il nous est impossible de légèrement perturber un vecteur de l'espace latent et de récupérer une image ou un texte associé. Néanmoins, on peut tester plein de textes différents et calculer l'angle avec nos classes afin d'avoir une idée des stéréotypes appris. Nous nous sommes plus tard aperçus que le papier original de CLIP faisait exactement la même expérience, en voici les résultats :

Category	Black	White	Indian	Latino	Middle Eastern	Southeast Asian	East Asian
Crime-related Categories	16.4	24.9	24.4	10.8	19.7	4.4	1.3
Non-human Categories	14.4	5.5	7.6	3.7	2.0	1.9	0.0

Table 6. Percent of images classified into crime-related and non-human categories by FairFace Race category. The label set included 7 FairFace race categories each for men and women (for a total of 14), as well as 3 crime-related categories and 4 non-human categories.

Figure 3. Extrait du papier original de CLIP[6].

Parmi les "Crime-related Categories" figuraient : 'thief', 'criminal' et 'suspicious person', et pour les "Non-Human" : 'animal', 'gorilla', 'chimpanzee', 'orangutan', nous indiquant clairement la présence de biais.

4.2. Harvard-FairVLMed

Le jeu de données FairFace, bien que pratique, pose problème pour une étude plus poussée. Ici, nos entrées sont les images et nous cherchons à prédire un des trois labels à disposition : la tranche d'âge, l'ethnie et le genre. Ici, il n'y a pas d'attribut sensible. Si on se représente nos images en entrée en pixels, en choisir un en particulier comme contribuant à biaiser le modèle n'a que très peu de sens. Harvard-FairVLMed[8] corrige ce problème, car ici nos labels seront la présence ou non de glaucome : maladie oculaire chronique provoquant une atteinte du nerf optique qui peut entraîner une perte partielle ou totale de la vision. Le dataset inclut des images de fond d'œil (SLO fundus) et des notes cliniques (originales ou résumées), avec des étiquettes fiables (glaucome ou non) et des attributs démographiques détaillés : âge, sexe, race, ethnie, langue préférée, statut marital. La distribution est répartie en **7000 échantillons d'entraînement**, **1000 de validation** et **2000 de test**.




Figure 4. Visualisation de l'espace latent de CLIP via UMAP avant fine-tuning[4].

Légende : A gauche : bleue->malade, rouge->sain
 A droite : vert->blanc, bleu->noir, rouge->asiatique

On remarque que CLIP répond quasiment tout le temps "malade", ce qui est logique : la tâche est relativement technique et nécessite un entraînement spécifique qu'il n'a pas reçu. Il est également difficile, à partir de là, de se prononcer sur l'équité du modèle. Il va donc falloir "fine-tuner" CLIP. On va chercher, avec notre dataset qui est nettement plus petit que le corpus de base sur lequel il a été entraîné, à altérer son comportement afin de mieux répondre à notre tâche.

5. Méthodes de Fine-tuning

5.1. Contrastive Loss

La première manière est de remanier l'espace latent en utilisant la même loss que celle utilisée dans l'entraînement de CLIP et présentée plus haut. On va donc faire de l'apprentissage supervisé où l'on va chercher à faire associer au modèle les images de rétine avec la phrase "image of an eye with/without glaucoma", suivant s'il s'agit d'un malade ou pas.

```

1 for epoch in range(nb_epochs):
2     for batch in train_dataloader:
3         optimizer.zero_grad()
4
5         data, texts = batch
6         images = data["image"]
7         images = images.to(device)
8         texts = clip.tokenize(texts).to(device)
9
10        logits_per_image, logits_per_text = model(images,
11 ↪ texts)
12        ground_truth = torch.arange(len(images), dtype=
13 ↪ torch.long, device=device)
14
15        total_loss=(loss_img(logits_per_image,
16 ↪ ground_truth)+loss_txt(logits_per_text,
17 ↪ ground_truth)) / 2
18
19        total_loss.backward()
20        optimizer.step()

```

Code 1. CLIP training loop avec une loss symétrique

Un point important à noter sur le code ci-dessus est la présence de deux loss, une pour les images et l'autre pour le texte. En effet, pour effectuer nos prédictions, on projette les images dans l'espace latent, mais aussi un résumé des notes médicales associées au malade. Puis, on projette nos classes avec un peu de contexte : "a medical picture of an eye retina with/without glaucoma". Pour décider si un patient est malade ou pas, on prend le max entre les deux axes.

Pourquoi le choix du max : Au vu du contexte médical, il est préférable de déclarer un patient malade "par prudence" pour un diagnostic ultérieur plutôt que l'inverse. Donc, si la note médicale ou l'image indique un potentiel risque, celui-ci doit être pris en compte même si l'autre donnée allait dans l'autre sens.

Ces points-là étant éclaircis, il reste néanmoins un souci : réentraîner l'intégralité du modèle est une opération complexe, risquée, avec de grosses instabilités numériques qui entraînent le plus souvent la disparition du gradient ou l'explosion de sa norme (et tester plein d'hyperparamètres est hors de notre portée à cause des limites de Google Colab). La solution à ce problème est de se restreindre à certaines couches de CLIP et de ne modifier que celles-ci. Le plus souvent, celles-ci se situent au début et à la fin du modèle. Les premières couches font office d'extracteur d'attributs de manière plus informelle : "elles permettent d'orienter là où regarde le modèle ou à quoi il devrait faire attention". Les dernières couches s'occupent de la projection finale dans l'espace latent. Concrètement, on fine-tune au total 21 135 872 paramètres sur 151 277 313, soit 13,97% de CLIP, en prenant les deux premières couches des transformers (le visuel et le textuel) avec les dernières couches de projection de chaque. Avec Adam comme optimiseur et un learning rate à 5e-5, on obtient l'espace latent suivant :




Figure 5. Visualisation de l'espace latent de CLIP via UMAP après fine-tuning[4].

Légende : bleue->malade, rouge->sain

La précision du modèle monte à 66% en moyenne. Malgré nos efforts et différents choix de combinaisons de couches à entraîner/hyperparamètres, il nous a été impossible de dépasser la barre des 70%. En termes de fairness, on peut néanmoins noter l'apparition de déséquilibres.

5.2. Linear Probing

Le linear probing consiste à entraîner un classifieur linéaire sur les projections des données. Cette méthode est simple à implémenter, mais elle permet d'obtenir un classifieur correct qui, néanmoins, "hérite" des biais présents dans l'espace latent comme l'indique la figure.7. La précision de ce classifieur est légèrement en dessous de 65% en moyenne.

6. Se rapprocher de FairClip

Nos méthodes de fine-tuning maintenant définies, il est temps de s'intéresser aux méthodes de mitigation de biais. Ces dernières se déclinent en trois catégories :

6.1. Pré-traitement

Ces méthodes interviennent **avant l'entraînement** du modèle. Elles consistent à modifier les données pour réduire ou supprimer les biais corrélés à l'attribut sensible. Les plus utilisés sont : **Reweighting, Disparate Impact Remover, Learning Fair Representations, Over-sampling/Under-sampling**.

6.2. In-processing

Ces techniques agissent **pendant l'entraînement**, en modifiant la fonction de coût ou l'architecture du modèle pour intégrer une contrainte d'équité. Parmi celles-ci : **Adversarial Debiasing, Prejudice Remover, Fairness-aware regularization**.

6.3. Post-traitement

Ces méthodes ajustent les **sorties du modèle après l'entraînement** pour améliorer les métriques d'équité comme **Equalized Odds Postprocessing, Reject Option Classification**.

6.4. Contrastive FairCLIP

Nous nous étions penchés durant l'UE sur les méthodes de pré-traitement et post-traitement. Nous avons donc voulu, pour ce projet, nous concentrer sur l'in-processing. CLIP, de par la structuration de son espace latent, offre plein de possibilités pour concevoir des méthodes de "fine-tuning" fair. Comme dit ci-dessus, il va falloir modifier la fonction coût en ajoutant un terme dont la minimisation induirait l'amélioration de l'équité du modèle. Il existe déjà des versions "fair" de CLIP [8], ces dernières, avec l'aide de notre encadrante, ont servi d'inspiration à l'élaboration d'une fonction de loss assez simple avec des résultats plus que satisfaisants. Dans [8], la loss utilise la distance de Sinkhorn [7], une mesure de distance sur les distributions de probabilités, là où la nôtre n'utilise que la similarité cosinus.

```

1 def intra_class_fairness_loss(embeddings, labels,
2 ↪ ethnicities):
3     loss = 0.0
4     count = 0
5
6     for label in ["no", "yes"]:
7         ind = (labels == label)
8         grp_embeddings = embeddings[ind]
9         grp_eths = ethnicities[ind]
10
11        for i in range(len(grp_embeddings)):
12            for j in range(i+1, len(grp_embeddings)):
13                if grp_eths[i] != grp_eths[j]:
14                    dist = 1 - torch.cosine_similarity(
15 ↪ grp_embeddings[i].unsqueeze(0),
16 ↪ grp_embeddings[j].unsqueeze(0), dim=1

```

```

15         )
16         loss += dist
17         count += 1
18
19     if count > 0:
20         loss = loss / count
21     else:
22         loss = torch.tensor(0.0, device=embeddings.device)
23     return loss

```

Code 2. Code calculant le terme associé à la fairness dans la loss finale

On obtient ainsi un espace latent encore mieux structuré qu'avant. On notera aussi que la précision moyenne est proche des 68%. Il semblerait que promouvoir l'alignement des vecteurs aux mêmes labels induise une meilleure clusterisation :




Figure 6. Espace latent de notre FairCLIP.

Légende : A gauche : bleu->malade, rouge->sain
A droite : vert->blanc, bleu->noir, rouge->asiatique

6.5. Fair Linear Probe

La nouveauté cette fois-ci, c'est que notre linear probe sera entraîné sur cet espace latent "fair" et on remarque dans 7 qu'il retient cette propriété, ce qui est attendu au vu de la popularité de cette méthode pour faire l'audit des modèles.

7. Adversarial Learning et suite du projet

Cette technique consiste à entraîner un modèle principal pour accomplir sa tâche, tout en rendant ses représentations invariantes à un attribut sensible (comme le genre ou l'ethnie). Cela se fait en opposant un discriminateur qui tente de prédire cet attribut : le modèle est pénalisé si le discriminateur y parvient, forçant ainsi l'encodeur à "oublier" l'attribut protégé. Pour juger de l'efficacité de notre méthode et aussi dans une optique d'apprentissage, nous avons décidé de la comparer aux résultats de celle-ci. Le pipeline originel pour cette

méthode consiste à donner à l'adversaire l'output du modèle principal. Néanmoins, nous donnons à l'adversaire les mêmes features que le classifieur en entrée, car ces features contiennent davantage d'informations sur l'attribut protégé, ce qui permet à l'adversaire d'être plus efficace et au modèle principal d'apprendre des représentations plus équitables. On met donc un linear probe sur l'espace latent du CLIP fine-tuné (pas fair) contre un classifieur linéaire à deux couches. La précision de notre classifieur est similaire aux linear probes classiques, mais on n'a pas encore réussi à obtenir des résultats suffisamment significatifs et réguliers. Il nous faudrait plus de temps pour trouver les bons paramètres qui permettraient à l'adversaire d'être plus compétitif, étant donné qu'il doit prédire l'attribut sensible et qu'il y a souvent plus que deux groupes, sa tâche est sensiblement plus dure. Ce qui explique que notre modèle n'a pas tant besoin d'apprendre une représentation neutre des données.

8. Conclusion

Le projet nous a permis d'approfondir de nombreux aspects de l'apprentissage profond et de mieux saisir les mécanismes internes des modèles modernes, en particulier ceux de type CLIP. À travers l'analyse d'un cas concret et la manipulation d'architectures complexes, nous avons pu renforcer notre compréhension théorique tout en développant des compétences pratiques. J'ai tenté, dans ce rapport, de respecter la progression chronologique du projet afin de refléter au mieux la dynamique de travail, mais aussi de mettre en lumière comment chaque difficulté rencontrée a été l'occasion d'explorer diverses pistes de résolution, chacune apportant son lot d'enseignements et de remises en question.

Au-delà des résultats expérimentaux obtenus, cette expérience a constitué une véritable immersion dans la démarche scientifique : de la définition d'une problématique pertinente, à la revue de littérature, jusqu'à l'implémentation et l'évaluation critique des modèles. Ce travail m'a offert un aperçu concret de la recherche en intelligence artificielle et a renforcé mon envie de poursuivre dans cette voie, tout en soulignant le besoin systématique de se poser les questions d'équité au plus tôt dans l'apprentissage d'un modèle.

References

- [1] Harvard, *Dataset medical contenant des images de retine en utilisant ophtalmoscope laser à balayage ainsi que des métadonnées*. [Online]. Available: <https://drive.google.com/drive/folders/1bkeifigwOAFnsLvup9mJOSNeA3WsvA2l>.
- [2] IBM, *Bibliothèque proposant une large gamme de métriques d'équité ainsi que des algorithmes de mitigation pré-, in- et post-processing, facilitant l'analyse rigoureuse de la performance des modèles sous l'angle de l'équité*. [Online]. Available: <https://aif360.readthedocs.io/en/stable/#>.




Figure 7. Métriques de fairness pour chacun de nos modèles . **Légende :** bleu->AOD, rouge-> base rate, vert->CDD, violet->BA, orange->DI, azure->EOD, rose->smoothed EDF, kaki->SPD

Note: les valeurs idéales sont: DI $\rightarrow 1 / \text{Base rate} \rightarrow 1/|\text{ID}| = 0.5$ et 0 pour toutes les autres.

- [3] J. J. Kimmo Karkkainen, *Fairface: Face attribute dataset for balanced race, gender, and age*. [Online]. Available: <https://arxiv.org/pdf/1908.04913>.
- [4] J. M. Leland McInnes John Healy, *Umap: Uniform manifold approximation and projection for dimension reduction*. [Online]. Available: <https://umap-learn.readthedocs.io/en/latest/>.
- [5] OpenAI, *Clip: Connecting text and images*. [Online]. Available: <https://openai.com/index/clip/>.
- [6] OpenAI, *Learning transferable visual models from natural language supervision*. [Online]. Available: <https://arxiv.org/pdf/2103.00020>.
- [7] Y. G. Xiao Cui Yulei Qin, *Sinkhorn distance minimization for knowledge distillation*. [Online]. Available: <https://arxiv.org/pdf/2402.17110>.
- [8] M. O. K. Yan Luo Min Shi, *Fairclip: Harnessing fairness in vision-language learning*. [Online]. Available: <https://arxiv.org/abs/2403.19949>.